

Otimização de hiperparâmetros de redes MLP para correção temporal de valores de PM2.5 utilizando busca aleatória

Matheus L. T. de Farias

Universidade Federal de Campina Grande (UFCG)
Programa de Pós-Graduação em Engenharia Elétrica - PPgEE
Processamento Adaptativo de Sinais

Junho de 2026

Roteiro da Apresentação

- 1 Introdução
- 2 Fundamentação Teórica
- 3 Base de Dados
- 4 Reprodução Original
- 5 Otimização Usando Busca Aleatória
- 6 Resultados
- 7 Conclusões

- Poluição atmosférica por PM2.5 traz altos riscos à saúde pública. Monitoramento constante é exigido.
- Estações de monitoramento de alta precisão são caras e de uso restrito.
- Sensores de baixo custo. Permitem ampla cobertura espacial, mas sofrem com menor precisão e alta sensibilidade a fatores climáticos (umidade, temperatura).
- Modelagem de correção temporal utilizando redes *Multi-Layer Perceptron* (MLP), conforme proposto por Casari et al. (2023).
- Redes MLP são altamente sensíveis à escolha dos hiperparâmetros. Configurações semelhantes podem ocasionar comportamentos distintos.

- 1 Reproduzir a metodologia original proposta por Casari et al. para o melhor modelo desenvolvido pelos autores (AirMLP7-1500).
- 2 Implementar um algoritmo sistemático de Busca Aleatória (*Random Search*) para investigar novas configurações hiperparamétricas a fim de superar a performance da abordagem original.

Fundamentação Teórica: *Perceptron*

O *Perceptron* (neurônio) é a unidade base da rede MLP. A operação realizada pelo j -ésimo neurônio na camada $i + 1$ consiste em uma combinação linear seguida de uma função de ativação não linear $f(\cdot)$:

$$z_j^{(i+1)} = f\left(w_j^{(i)T} z^{(i)} + b_j^{(i+1)}\right) \quad (1)$$

Onde:

- $z^{(i)}$: Vetor de saídas da camada i .
- $w_j^{(i)}$: Vetor de pesos entre as camadas.
- $b_j^{(i+1)}$: Viés (*bias*).
- $z_j^{(i+1)}$: Saída do neurônio.




Figura: Estrutura básica de um neurônio.

- Junção de várias camadas, cada uma com várias unidades de *perceptrons* densamente conectada.
- Três camadas principais
 - Camada de Entrada.
 - Camada(s) Ocultas.
 - Camada de Saída.
- Camadas ocultas geralmente possuem a mesma função de ativação.
- A camada de saída possui função de ativação diferente, dependendo da aplicação.




Figura: Estrutura geral de uma rede MLP.

Fundamentação Teórica - Propagação Direta

A propagação direta consiste no fluxo de informações da camada de entrada até a saída. Matricialmente, o processamento para obter a saída da camada $i + 1$ ocorre em duas etapas:

1. Cálculo da ativação:

$$\mathbf{a}^{(i+1)} = \mathbf{W}^{(i)}\mathbf{z}^{(i)} + \mathbf{b}^{(i+1)} \quad (2)$$

- $\mathbf{W}^{(i)}$: Matriz de pesos conectando a camada i à camada $i + 1$.
- $\mathbf{z}^{(i)}$: Vetor com as saídas da camada i .
- $\mathbf{b}^{(i+1)}$: Vetor de vieses da camada $i + 1$.

2. Aplicação da Não Linearidade:

$$\mathbf{z}^{(i+1)} = f(\mathbf{a}^{(i+1)}) \quad (3)$$

- $f(\cdot)$: Função de ativação (ex: ReLU, tanh). É o elemento crucial que permite à rede mapear relações não lineares complexas nos dados.

O objetivo do treinamento é encontrar o conjunto de parâmetros (pesos e vieses) que minimizam uma Função de Custo J .

Otimização via Gradiente:

$$W^{(i)}[k + 1] = W^{(i)}[k] - \mu \nabla_{W^{(i)}} J \quad (4)$$

$$b^{(i)}[k + 1] = b^{(i)}[k] - \mu \nabla_{b^{(i)}} J \quad (5)$$

- μ : Taxa de aprendizado.
- $\nabla_{W^{(i)}} J$: Gradiente do erro em relação à matriz de pesos.
- $\nabla_{b^{(i)}} J$: Gradiente do erro em relação ao vetor de vieses.

Backpropagation:

- O gradiente calculado nas camadas de saída é retropropagado para computar os gradientes das camadas iniciais.
- Otimizadores adaptativos (como o **Adam**) dinamizam esse passo.

- Parâmetros externos ao processo de treinamento da rede.
- Definem aspectos da arquitetura e do treinamento da rede.
- Responsáveis pela eficácia e eficiência da rede.
- Exemplos:
 - Número de camadas.
 - Número de neurônios por camada.
 - Função de ativação.
 - Número de épocas.
 - Tamanho do lote.
 - Taxa de aprendizado.
 - etc...

- Supera o *Grid Search* devido ao fenômeno da baixa dimensionalidade efetiva (apenas um subconjunto de hiperparâmetros domina a resposta da rede).
- Permite paralelização e controle rigoroso do orçamento computacional.
- Etapas:
 - 1 Delimitação do espaço hiperparamétrico.
 - 2 Amostragem estocástica do espaço hiperparamétrico.
 - 3 Construção e treinamento do modelo.
 - 4 Avaliação dos resultados obtidos.
 - 5 Repetição a partir do passo 2 até que o critério de parada seja atingido.
 - 6 Seleção do conjunto de hiperparâmetros que proporcionou o melhor desempenho ao modelo.

Fundamentação Teórica - Coeficiente de Determinação (R^2)

Métrica que quantificar a proporção da variabilidade dos dados observados que pode ser explicada pelo modelo preditivo.

Formulação Matemática:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (6)$$

Onde:

- y_i : Valor real (observado) da concentração de PM2.5.
- $\hat{y}_i$: Valor estimado pela rede neural MLP.
- $\bar{y}$: Média de todos os valores reais observados.

Interpretação dos Resultados:

- $R^2 = 1$: Predição perfeita.
- $R^2 \approx 0$: Equivalente a prever sempre a média.
- $R^2 < 0$: Modelo erra mais do que uma predição constante baseada na média.

Os dados utilizados para o treinamento e validação dos modelos provêm do repositório de Casari et al. (2023), coletados em áreas verdes da cidade de Turim, na Itália.

Dispositivos e Coleta:

- **Sensores de Baixo Custo:** 5 dispositivos Arianna (Wiseair).
- **Estação de Referência:** Arpa Piemonte.

Período e Taxa de Amostragem:

- **Campanha:** 4 meses totais (Mar-Abr, Out-Nov).
- **Amostragem:** Dispositivos Arianna medem a cada 15 minutos; a Estação de Referência registra 1 medição por hora.

Grandezas Utilizadas no Modelo:

- | | |
|--|---|
| • Concentração de PM2.5 [$\mu\text{g}/\text{m}^3$] | • Pressão atmosférica [hPa] |
| • Umidade relativa do ar [%] | • Cobertura de nuvens [%] |
| • Temperatura [$^{\circ}\text{C}$] | • Velocidade do vento [m/s] |

- Remoção de dados faltantes.
- Equalização da taxa de amostragem.
- Janelamento dos dados.
- Separação aleatória entre dados de treino e teste.
 - 75% treinamento.
 - 25% teste.

Pré-processamento - *Data Augmentation*

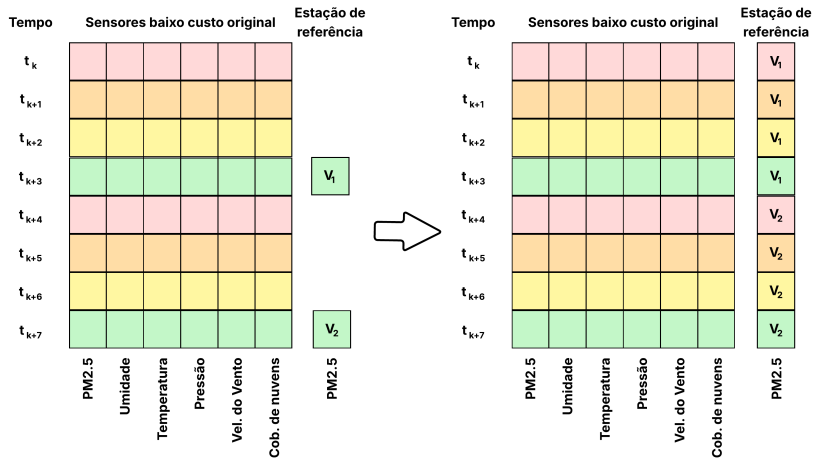


Figura: *Data Augmentation* dos dados.

Pré-processamento - Janelamento Temporal




Figura: Janelamento temporal dos dados.

Na implementação original, foi realizada inicialmente uma busca em grade (*grid search*), seguida de uma busca empírica para refinamento dos hiperparâmetros.

Tabela: Espaço de busca de hiperparâmetros avaliado no modelo original

Hiperparâmetro	Valores explorados
Número de camadas	6, 7 e 8
Neurônios por camada	300, 500, 700, 900, 1100 e 1500
Tamanho da janela	6, 12 e 20 amostras
Tamanho do lote	64, 256 e 512

Reprodução Original - Reprodução do Melhor Modelo (AirMLP7-1500)

A reprodução utilizou os hiperparâmetros otimizados durante a etapa de busca, juntamente com os hiperparâmetros fixos propostos pelos autores.

Tabela: Configuração e hiperparâmetros do melhor modelo original (AirMLP7-1500)

Hiperparâmetro	Valor adotado
Número de camadas	7
Neurônios por camada	1500
Janela temporal	20 amostras
Tamanho do lote	64
Função de ativação	ReLU
Função de perda	L1 (Erro Absoluto Médio)
Número de épocas	200
Otimizador	RAdam
Taxa de aprendizado	$5 \cdot 10^{-5}$

Falha da referência: Ausência de um conjunto de validação durante a busca. Risco de viés de teste.

Abordagem Proposta:

- **Divisão dos Dados:** 75% Treino, 12,5% Validação, 12,5% Teste.
- **Pré-processamento:** Troca do *Batch Normalization* por normalização *Standard Scaler* prévia à rede
- **Mecanismo de Controle:** *Early Stopping* com paciência de 15 épocas.
- **Duas Etapas de Busca:**
 - 1 Exploração ampla (400 iterações).
 - 2 Refinamento dos melhores subespaços (400 iterações).

Tabela: Espaço de busca de hiperparâmetros adotado para a otimização via Busca Aleatória

Hiperparâmetro	Valores - Etapa 1	Valores - Etapa 2
Número de camadas ocultas	4 a 10	4 a 7
Neurônios por camada	64, 128, 256 e 512	256, 512 e 1024
Janelamento temporal	10, 20 e 30	20 e 30
Tamanho do lote	64, 128, 256 e 512	64 e 128
Função de ativação	ReLU, tanh e σ	ReLU e tanh
Taxa de aprendizado	$\text{LogUniform}(10^{-5}, 10^{-2})$	$\text{LogUniform}(10^{-4}, 10^{-2.5})$

Resultados da Reprodução do Modelo Original




Figura: Evolução do erro de treinamento e teste.




Figura: Estimativa PM2.5 (primeiras 200 amostras).

Resultado: $R^2 = 0.920$ (referência: $R^2 = 0.932$)

Resultados da Otimização: Etapa 1 (Exploração)

Tabela: Melhores configurações obtidas na busca aleatória na Etapa 1.

Janelas	Camadas Ocultas	Neurônios	Função	T. aprendizado	Lote	R^2
30	4	512	ReLU	0.000875	64	0.941
20	10	512	tanh	0.000177	64	0.940
20	6	256	tanh	0.000659	64	0.939
20	5	512	ReLU	0.000841	128	0.938
20	4	512	ReLU	0.001470	512	0.936
20	7	256	tanh	0.002228	256	0.934
20	5	256	ReLU	0.001776	256	0.934
20	8	256	ReLU	0.001947	512	0.932
30	4	512	ReLU	0.000239	64	0.930
20	5	256	tanh	0.001461	64	0.929

Resultados da Otimização: Etapa 1 (Exploração)




Figura: Impacto da taxa e função de ativação.




Figura: Mapa de calor (Camadas x Neurônios).

Resultados da Otimização: Etapa 1 (Exploração)




Figura: Distribuição do R^2 em relação ao tamanho da janela e do lote.

Resultados da Otimização: Etapa 2 (Refinamento)

Tabela: Melhores configurações obtidas na busca aleatória na Etapa 2

Janelas	Camadas Ocultas	Neurônios	Função	T. aprendizado	Lote	R^2
30	4	1024	ReLU	0.000352	64	0.950
20	4	1024	ReLU	0.000403	64	0.949
30	5	1024	ReLU	0.000369	128	0.947
30	6	1024	ReLU	0.000200	128	0.947
30	7	1024	tanh	0.000135	64	0.946
20	5	1024	ReLU	0.000614	128	0.945
20	4	512	ReLU	0.000577	64	0.945
20	5	1024	ReLU	0.000601	128	0.945
30	4	1024	ReLU	0.000295	64	0.945
20	4	1024	ReLU	0.000573	128	0.944

Resultados da Otimização: Etapa 2 (Refinamento)




Figura: Impacto da taxa e função de ativação.




Figura: Mapa de calor (Camadas x Neurônios).

Resultados da Otimização: Etapa 2 (Refinamento)




Figura: Avaliação refinada dos tamanhos de janela e lote.

Tabela: Configuração e hiperparâmetros do melhor modelo definido pela busca aleatória

Hiperparâmetro	Valor adotado
Número de camadas ocultas	4
Neurônios por camada	1024
Janelamento temporal	30 amostras
Tamanho do lote	64
Função de ativação	ReLU
Função de perda	Erro Absoluto Médio
Número de épocas	200
Otimizador	Adam
Taxa de aprendizado	$3.52 \cdot 10^{-4}$

O Melhor Modelo Otimizado




Figura: Treinamento com *Early Stopping* (interrompido na época 185).

Resultado: $R^2 = 0.944$ (Referência $R^2 = 0.932$)




Figura: Estimativa PM2.5 (primeiras 200 amostras) após otimização

- A reprodução confirmou a capacidade das MLPs na correção de leituras de sensores de baixo custo para PM2.5.
- O emprego de conjuntos independentes de validação corrigiu a falha metodológica identificada na abordagem original.
- Redes rasas com elevado número de neurônios mostraram-se mais adequadas para este problema.
- O desempenho obtido superou a referência original ($R^2 = 0.944$ vs 0.932), evidenciando a eficiência da busca aleatória de hiperparâmetros e a robustez de uma abordagem experimental estruturada.

Obrigado!

Perguntas e Discussão

matheuslucas.farias@ee.ufcg.edu.br